Initiation aux logiciels R et RStudio

Pour l'analyse de données et les représentations graphiques

Benoît Simon-Bouhet

IFP Énergies Nouvelles

Juin 2025

Manipuler des données

Manipuler des données

Préambule

Dans cette partie, nous allons découvrir comment transformer nos données à l'aide du package `dplyr`.

Comme dans la partie consacrée aux visualisations graphiques, nous utiliserons le jeu de données `flights` listant les caractéristiques de tous les vols au départ de New York City en 2013.

Nous découvrirons également ce qu'est le "pipe".

Pour tout cela, nous aurons besoin d'installer 2 packages :

```
## install.packages("tidyverse")
## install.packages("nycflights13")
library(tidyverse)
library(nycflights13)
```

Manipuler des données

nycflights13

Jetons à nouveau un œil aux données contenues dans `flights` :

```
flights

# A tibble: 336,776 x 19
    year month   day dep_time sched_dep_time dep_delay arr_time
   <int> <int> <int>    <int>          <int>     <dbl>    <int>
 1  2013     1     1      517            515         2      830
 2  2013     1     1      533            529         4      850
 3  2013     1     1      542            540         2      923
 4  2013     1     1      544            545        -1     1004
 5  2013     1     1      554            600        -6      812
 6  2013     1     1      554            558        -4      740
 7  2013     1     1      555            600        -5      913
 8  2013     1     1      557            600        -3      709
 9  2013     1     1      557            600        -3      838
10  2013     1     1      558            600        -2      753
# i 336,766 more rows
# i 12 more variables: sched_arr_time <int>, arr_delay <dbl>,
#   carrier <chr>, flight <int>, tailnum <chr>, origin <chr>,
#   dest <chr>, air_time <dbl>, distance <dbl>, hour <dbl>,
#   minute <dbl>, time_hour <dttm>
```

Manipuler des données

dplyr : les bases

Manipuler des données avec dplyr revient en général à effectuer les 5 actions suivantes, qui correspondent chacune à une fonction portant le nom d'un verbe :

1. Choisir des observations en fonction de leur valeur : `filter()`
2. Réordonner les lignes : `arrange()`
3. Choisir des variables par leur nom : `select()`
4. Créer de nouvelles variables en combinant des variables existantes : `mutate()`
5. Regrouper de nombreuses valeurs sous la forme d'un résumé unique : `summarise()`

Toutes ces fonctions peuvent être utilisées en conjonction avec `group_by()`, qui permet de ne plus travailler sur l'ensemble du jeu de données, mais sur des sous-groupes spécifiques.

Manipuler des données

`dplyr` : les bases

Ces 6 fonctions constituent les verbes de la langue utilisée pour la manipulation de données

Ils travaillent tous de la même façons :

- Le premier argument est un `data.frame` (ou un `tibble`)
- Les arguments suivants décrivent ce qui doit être fait avec les données, en utilisant les noms de variables (sans les guillemets)
- Le résultat est un nouveau `data.frame` (ou un nouveau `tibble`)

Prises globalement, ces propriétés rendent aisé l'enchaînement de multiples opérations simples permettant d'obtenir des résultats complexes.

Manipuler des données : 1. Filtrer

1. Filtrer des données

La fonction `filter()`

`filter()` permet de récuppérer des observations grâce à leur valeur.

Par exemple, pour sélectionner tous les vols du premier janvier :

```
filter(flights, month == 1, day == 1)
```

```
# A tibble: 842 x 19
    year month   day dep_time sched_dep_time dep_delay arr_time
   <int> <int> <int>    <int>          <int>     <dbl>    <int>
 1  2013     1     1      517            515         2      830
 2  2013     1     1      533            529         4      850
 3  2013     1     1      542            540         2      923
 4  2013     1     1      544            545        -1     1004
 5  2013     1     1      554            600        -6      812
 6  2013     1     1      554            558        -4      740
 7  2013     1     1      555            600        -5      913
 8  2013     1     1      557            600        -3      709
 9  2013     1     1      557            600        -3      838
10  2013     1     1      558            600        -2      753
# i 832 more rows
# i 12 more variables: sched_arr_time <int>, arr_delay <dbl>,
#   carrier <chr>, flight <int>, tailnum <chr>, origin <chr>,
#   dest <chr>, air_time <dbl>, distance <dbl>, hour <dbl>,
#   minute <dbl>, time_hour <dttm>
```

1. Filtrer des données

`filter()` : opérateurs logiques

Pour sélectionner des données, nous avons besoin de réaliser des comparaisons.

- `>` Supérieur à
- `>=` Supérieur ou égal à
- `<` Inférieur
- `<=` Inférieur ou égal à
- `==` Égal à
- `!=` Différent de

Attention à l'arithmétique en "point flottant" :

```
sqrt(2) ^ 2 == 2
```

```
[1] FALSE
```

```
1 / 49 * 49 == 1
```

```
[1] FALSE
```

1. Filtrer des données

`filter()` : opérateurs logiques

Pour enchaîner les comparaisons, nous avons besoin d'utiliser des opérateurs logiques.

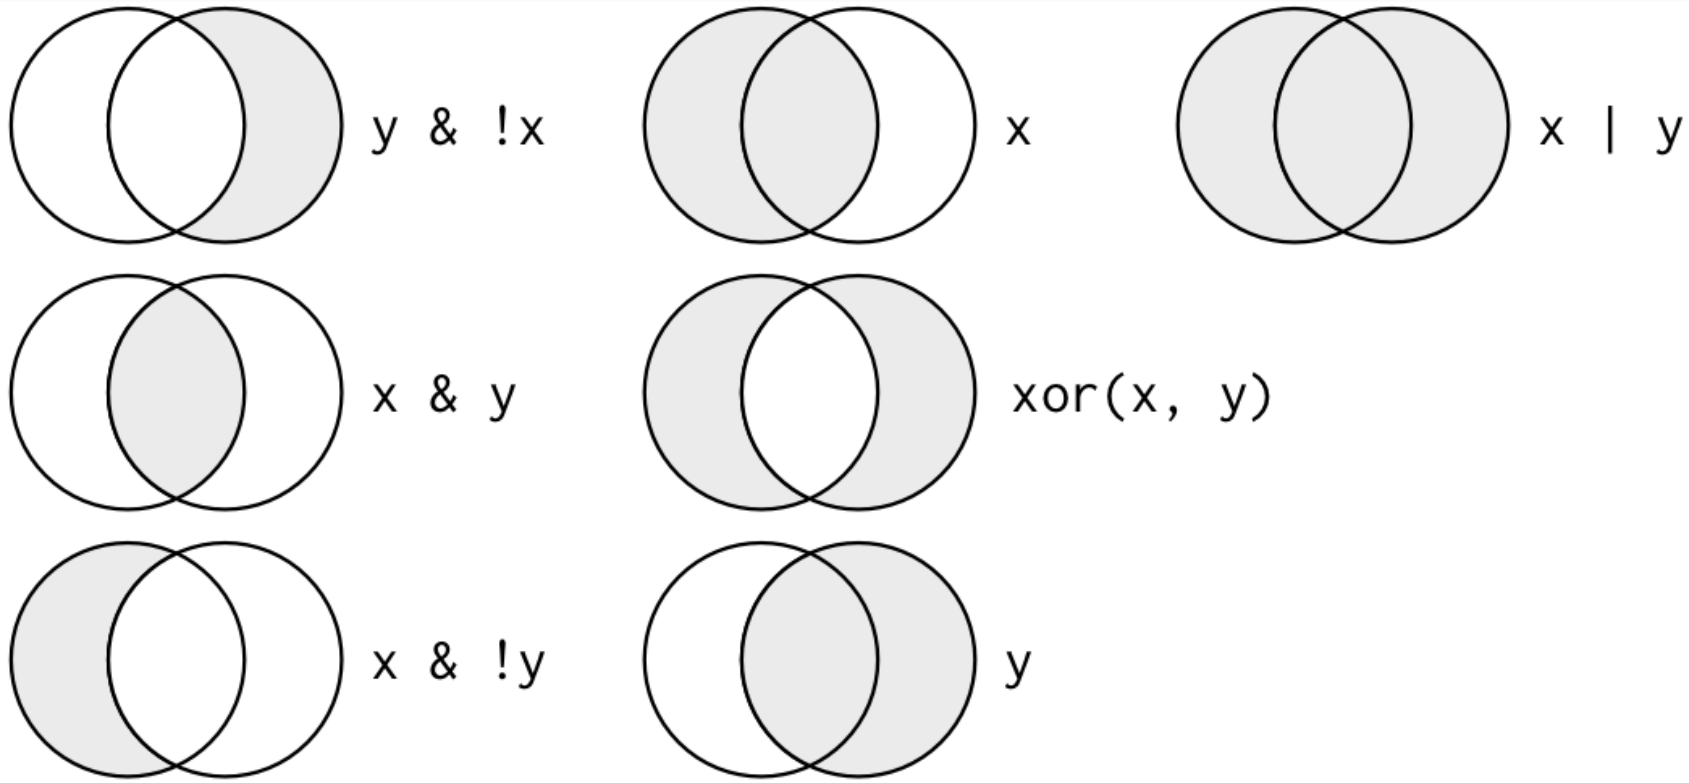

1. Filtrer des données

`filter()` : opérateurs logiques

Par exemple, pour afficher tous les vols de Novembre ou Décembre :

```
filter(flights, month == 11 | month == 12)
```

```
# A tibble: 55,403 x 19
    year month   day dep_time sched_dep_time dep_delay arr_time
   <int> <int> <int>    <int>          <int>     <dbl>    <int>
 1  2013    11     1        5           2359         6      352
 2  2013    11     1       35           2250       105      123
 3  2013    11     1      455            500        -5      641
 4  2013    11     1      539            545        -6      856
 5  2013    11     1      542            545        -3      831
 6  2013    11     1      549            600       -11      912
 7  2013    11     1      550            600       -10      705
 8  2013    11     1      554            600        -6      659
 9  2013    11     1      554            600        -6      826
10  2013    11     1      554            600        -6      749
# i 55,393 more rows
# i 12 more variables: sched_arr_time <int>, arr_delay <dbl>,
#   carrier <chr>, flight <int>, tailnum <chr>, origin <chr>,
#   dest <chr>, air_time <dbl>, distance <dbl>, hour <dbl>,
#   minute <dbl>, time_hour <dttm>
```

1. Filtrer des données

`filter()` : opérateurs logiques

Un autre opérateur souvent utile : %in%

```
filter(flights, month %in% c(11, 12))
```

```
# A tibble: 55,403 x 19
    year month   day dep_time sched_dep_time dep_delay arr_time
   <int> <int> <int>    <int>          <int>     <dbl>    <int>
 1  2013    11     1        5           2359         6      352
 2  2013    11     1       35           2250       105      123
 3  2013    11     1      455            500        -5      641
 4  2013    11     1      539            545        -6      856
 5  2013    11     1      542            545        -3      831
 6  2013    11     1      549            600       -11      912
 7  2013    11     1      550            600       -10      705
 8  2013    11     1      554            600        -6      659
 9  2013    11     1      554            600        -6      826
10  2013    11     1      554            600        -6      749
# i 55,393 more rows
# i 12 more variables: sched_arr_time <int>, arr_delay <dbl>,
#   carrier <chr>, flight <int>, tailnum <chr>, origin <chr>,
#   dest <chr>, air_time <dbl>, distance <dbl>, hour <dbl>,
#   minute <dbl>, time_hour <dttm>
```

1. Filtrer des données

`filter()` : opérateurs logiques

Loi de Morgan :

- `!(x & y)` est équivalent à `!x | !y`
- `!(x | y)` est équivalent à `!x & !y`

Ainsi, pour trouver les vols qui n'ont pas eu plus de 2h de retard (ni au départ, ni à l'arrivée), les 2 commandes suivantes sont équivalentes [1] :

```
filter(flights, !(arr_delay > 120 | dep_delay > 120))
filter(flights, arr_delay <= 120, dep_delay <= 120)
```

1. Personnellement, je trouve la seconde plus facile à comprendre !

1. Filtrer des données

`filter()` : exercices

A. Trouver tous les vols qui :

1. ont eu 2 heures de retard ou plus à l'eur arrivée
2. ont volé vers houston (`IAH` ou `HOU`)
3. ont été affrétés par United Airlines, American Airlines ou Delta Airlines
4. ont décollé l'été (juillet, août et septembre)
5. sont arrivés avec plus de 2h de retard mais on décollé à l'heure
6. sont partis avec au moins une heure de retard, mais ont rattrappé au moins 30 minutes de retard en vol
7. ont décollé entre minuit et 6h du matin (inclus)

B. Une fonction utile de dplyr est `between()`. Que fait cette fonction ? Utilisez là pour simplifier les réponses aux questions précédentes.

C. Combien de vols ont un `dep_time` manquant ? Pour ces vols, quelles autres variables sont manquantes ? Que peuvent représenter ces lignes ?

Manipuler des données : 2. Trier

2. Trier des données

La fonction `arrange()`

`arrange()` fonctionne comme `filter()`, mais au lieu de sélectionner des lignes, elle permet de modifier l'ordre des lignes d'un tableau.

```
arrange(flights, year, month, day)
```

```
# A tibble: 336,776 x 19
    year month   day dep_time sched_dep_time dep_delay arr_time
   <int> <int> <int>    <int>          <int>     <dbl>    <int>
 1  2013     1     1      517            515         2      830
 2  2013     1     1      533            529         4      850
 3  2013     1     1      542            540         2      923
 4  2013     1     1      544            545        -1     1004
 5  2013     1     1      554            600        -6      812
 6  2013     1     1      554            558        -4      740
 7  2013     1     1      555            600        -5      913
 8  2013     1     1      557            600        -3      709
 9  2013     1     1      557            600        -3      838
10  2013     1     1      558            600        -2      753
# i 336,766 more rows
# i 12 more variables: sched_arr_time <int>, arr_delay <dbl>,
#   carrier <chr>, flight <int>, tailnum <chr>, origin <chr>,
#   dest <chr>, air_time <dbl>, distance <dbl>, hour <dbl>,
#   minute <dbl>, time_hour <dttm>
```

2. Trier des données

La fonction arrange( )

La fonction desc() permet de trier par ordre décroissant :

```
arrange(flights, desc(dep_delay))

# A tibble: 336,776 x 19
    year month   day dep_time sched_dep_time dep_delay arr_time
   <int> <int> <int>    <int>          <int>     <dbl>    <int>
 1  2013     1     9      641            900      1301     1242
 2  2013     6    15     1432           1935      1137     1607
 3  2013     1    10     1121           1635      1126     1239
 4  2013     9    20     1139           1845      1014     1457
 5  2013     7    22      845           1600      1005     1044
 6  2013     4    10     1100           1900       960     1342
 7  2013     3    17     2321            810       911      135
 8  2013     6    27      959           1900       899     1236
 9  2013     7    22     2257            759       898      121
10  2013    12     5      756           1700       896     1058
# i 336,766 more rows
# i 12 more variables: sched_arr_time <int>, arr_delay <dbl>,
#   carrier <chr>, flight <int>, tailnum <chr>, origin <chr>,
#   dest <chr>, air_time <dbl>, distance <dbl>, hour <dbl>,
#   minute <dbl>, time_hour <dttm>
```

2. Trier des données

La fonction arrange( )

Les valeurs manquantes sont toujours placées à la fin :

```
df <- tibble(x = c(5, 2, NA))
arrange(df, x)

# A tibble: 3 x 1
      x
  <dbl>
1     2
2     5
3    NA

arrange(df, desc(x))

# A tibble: 3 x 1
      x
  <dbl>
1     5
2     2
3    NA
```

2. Trier des données

`arrange()` : exercices

1. Trouvez les vols les plus retardés (au départ).
2. Trouvez les vols qui ont décollé le plus tôt (*i.e.* avec le plus d'avance)
3. Trouvez les vols les plus rapides (*i.e.* les plus courts)
4. Trouvez les vols les plus longs et les plus courts (en distance)

Manipuler des données : 3. Sélectionner

3. Sélectionner des données

La fonction `select()`

Il n'est pas rare de travailler avec des jeux de données contenant des centaines ou même des milliers de variables. Le 1er travail est alors souvent de sélectionner les variables utiles.

`select()` permet de zoomer rapidement sur un sous-ensemble de variables en utilisant des opérations sur les noms des variables.

`select()` n'est pas très utile pour `flights` car ce jeu de données ne compte que 19 variables. Néanmoins on peut malgré tout découvrir les grands principes.

3. Sélectionner des données

La fonction `select()`

Sélection de colonnes par leur nom :

```
select(flights, year, month, day)
```

```
# A tibble: 336,776 x 3
    year month   day
   <int> <int> <int>
 1  2013     1     1
 2  2013     1     1
 3  2013     1     1
 4  2013     1     1
 5  2013     1     1
 6  2013     1     1
 7  2013     1     1
 8  2013     1     1
 9  2013     1     1
10  2013     1     1
# i 336,766 more rows
```

3. Sélectionner des données

La fonction `select()`

Sélection de toutes les colonnes entre year et day (inclues) :

```
select(flights, year:day)
```

```
# A tibble: 336,776 x 3
    year month   day
   <int> <int> <int>
 1  2013     1     1
 2  2013     1     1
 3  2013     1     1
 4  2013     1     1
 5  2013     1     1
 6  2013     1     1
 7  2013     1     1
 8  2013     1     1
 9  2013     1     1
10  2013     1     1
# i 336,766 more rows
```

3. Sélectionner des données

La fonction `select()`

Sélection de toutes les colonnes sauf celles entre year et day (inclues) :

```
select(flights, -(year:day))

# A tibble: 336,776 x 16
   dep_time sched_dep_time dep_delay arr_time sched_arr_time arr_delay
      <int>          <int>     <dbl>    <int>          <int>     <dbl>
 1      517            515         2      830            819        11
 2      533            529         4      850            830        20
 3      542            540         2      923            850        33
 4      544            545        -1     1004           1022       -18
 5      554            600        -6      812            837       -25
 6      554            558        -4      740            728        12
 7      555            600        -5      913            854        19
 8      557            600        -3      709            723       -14
 9      557            600        -3      838            846        -8
10      558            600        -2      753            745         8
# i 336,766 more rows
# i 10 more variables: carrier <chr>, flight <int>, tailnum <chr>,
#   origin <chr>, dest <chr>, air_time <dbl>, distance <dbl>,
#   hour <dbl>, minute <dbl>, time_hour <dttm>
```

3. Sélectionner des données

`select()` : fonctions d'aide

Il s'agit de fonctions qui permettent de sélectionner plusieurs variables à la fois avec plusieurs méthodes.

- `starts_with("abc")` : toutes les variables de le nom commence par "abc"
- `ends_with("abc")` : toutes les variables de le nom se termine par "xyz"
- `contains("ijk")` : toutes les variables de le nom contient "ijk"
- `num_range("x", 1:3)` : les variables dont le nom est x1, x2 et x3

3. Sélectionner des données

`select()` : renommer

```
select(flights, Depart = dep_time)
```

```
# A tibble: 336,776 x 1
   Depart
    <int>
 1    517
 2    533
 3    542
 4    544
 5    554
 6    554
 7    555
 8    557
 9    557
10    558
# i 336,766 more rows
```

3. Sélectionner des données

`select()` : renommer

Il est donc souvent plus pertinent d'utiliser `rename()`

```
rename(flights, Depart = dep_time)
```

```
# A tibble: 336,776 x 19
    year month   day Depart sched_dep_time dep_delay arr_time
   <int> <int> <int>  <int>          <int>     <dbl>    <int>
 1  2013     1     1    517            515         2      830
 2  2013     1     1    533            529         4      850
 3  2013     1     1    542            540         2      923
 4  2013     1     1    544            545        -1     1004
 5  2013     1     1    554            600        -6      812
 6  2013     1     1    554            558        -4      740
 7  2013     1     1    555            600        -5      913
 8  2013     1     1    557            600        -3      709
 9  2013     1     1    557            600        -3      838
10  2013     1     1    558            600        -2      753
# i 336,766 more rows
# i 12 more variables: sched_arr_time <int>, arr_delay <dbl>,
#   carrier <chr>, flight <int>, tailnum <chr>, origin <chr>,
#   dest <chr>, air_time <dbl>, distance <dbl>, hour <dbl>,
#   minute <dbl>, time_hour <dttm>
```

3. Sélectionner des données

`select()` : fonctions d'aide (*bis*)

`everything()` : sélectionne toutes les variables non listées :

```
select(flights, dep_delay, arr_delay, everything())

# A tibble: 336,776 x 19
   dep_delay arr_delay  year month   day dep_time sched_dep_time
       <dbl>     <dbl> <int> <int> <int>    <int>          <int>
 1         2        11  2013     1     1      517            515
 2         4        20  2013     1     1      533            529
 3         2        33  2013     1     1      542            540
 4        -1       -18  2013     1     1      544            545
 5        -6       -25  2013     1     1      554            600
 6        -4        12  2013     1     1      554            558
 7        -5        19  2013     1     1      555            600
 8        -3       -14  2013     1     1      557            600
 9        -3        -8  2013     1     1      557            600
10        -2         8  2013     1     1      558            600
# i 336,766 more rows
# i 12 more variables: arr_time <int>, sched_arr_time <int>,
#   carrier <chr>, flight <int>, tailnum <chr>, origin <chr>,
#   dest <chr>, air_time <dbl>, distance <dbl>, hour <dbl>,
#   minute <dbl>, time_hour <dttm>
```

3. Sélectionner des données

`select()` : exercices

1. Que se passe-t'il si on utilise plusieurs fois le même nom de variable avec `select()` ?

2. Que fait la fonction `one_of()` ? Pourquoi cette fonction peut-elle être utile avec un vecteur tel que :

```
vars <- c("year", "month", "day", "dep_delay", "arr_delay")
```

3. Le résultat de la commande suivante vous surprend-il ? Comment sont gérées, par défaut, les majuscules par les "helper functions" ? Comment peut-on changer ce comportement ?

```
select(flights, contains("TIME"))
```

Manipuler des données : 4. Modifier

4. Modifier des données

La fonction `mutate()` : principe

Mis à part la sélection de variables particulières avec `select()`, il est souvent utile de créer de nouvelles variables qui seront des fonctions de variables existantes.

C'est le rôle de `mutate()`

`mutate()` ajoute systématiquement les nouvelles variables à la fin du jeu de données fourni. Nous allons donc commencer par créer un jeu de données plus "étroit" afin de pouvoir visualiser les nouvelles variables que nous allons créer par la suite :

```
flights_sml <- select(flights, month:day,
                      ends_with("delay"),
                      distance,
                      air_time)
```

4. Modifier des données

La fonction `mutate()` : principe

```
flights_sml

# A tibble: 336,776 x 6
   month   day dep_delay arr_delay distance air_time
   <int> <int>     <dbl>     <dbl>    <dbl>    <dbl>
 1     1     1         2        11     1400      227
 2     1     1         4        20     1416      227
 3     1     1         2        33     1089      160
 4     1     1        -1       -18     1576      183
 5     1     1        -6       -25      762      116
 6     1     1        -4        12      719      150
 7     1     1        -5        19     1065      158
 8     1     1        -3       -14      229       53
 9     1     1        -3        -8      944      140
10     1     1        -2         8      733      138
# i 336,766 more rows
```

4. Modifier des données

mutate() : exemples

```
mutate(flights_sml,
       gain = dep_delay - arr_delay,
       speed = distance / air_time * 60)

# A tibble: 336,776 x 8
   month   day dep_delay arr_delay distance air_time  gain speed
   <int> <int>     <dbl>     <dbl>    <dbl>    <dbl> <dbl> <dbl>
 1     1     1         2        11     1400      227    -9  370.
 2     1     1         4        20     1416      227   -16  374.
 3     1     1         2        33     1089      160   -31  408.
 4     1     1        -1       -18     1576      183    17  517.
 5     1     1        -6       -25      762      116    19  394.
 6     1     1        -4        12      719      150   -16  288.
 7     1     1        -5        19     1065      158   -24  404.
 8     1     1        -3       -14      229       53    11  259.
 9     1     1        -3        -8      944      140     5  405.
10     1     1        -2         8      733      138   -10  319.
# i 336,766 more rows
```

4. Modifier des données

`mutate()` : exemples

Il est également possible d'utiliser des noms de variables juste créées :

```
mutate(flights_sml, gain = dep_delay - arr_delay,
                    hours = air_time / 60,
                    gain_per_hour = gain / hours)

# A tibble: 336,776 x 9
   month   day dep_delay arr_delay distance air_time  gain hours
   <int> <int>     <dbl>     <dbl>    <dbl>    <dbl> <dbl> <dbl>
 1     1     1         2        11     1400      227    -9 3.78
 2     1     1         4        20     1416      227   -16 3.78
 3     1     1         2        33     1089      160   -31 2.67
 4     1     1        -1       -18     1576      183    17 3.05
 5     1     1        -6       -25      762      116    19 1.93
 6     1     1        -4        12      719      150   -16 2.5
 7     1     1        -5        19     1065      158   -24 2.63
 8     1     1        -3       -14      229       53    11 0.883
 9     1     1        -3        -8      944      140     5 2.33
10     1     1        -2         8      733      138   -10 2.3
# i 336,766 more rows
# i 1 more variable: gain_per_hour <dbl>
```

4. Modifier des données

`mutate()` : alternative

Si l'on souhaite uniquement conserver les variables nouvellement créées, on utilise `transmute()` :

```
transmute(flights_sml, gain = dep_delay - arr_delay,
                       hours = air_time / 60,
                       gain_per_hour = gain / hours)

# A tibble: 336,776 x 3
    gain hours gain_per_hour
   <dbl> <dbl>         <dbl>
 1    -9 3.78          -2.38
 2   -16 3.78          -4.23
 3   -31 2.67         -11.6
 4    17 3.05           5.57
 5    19 1.93           9.83
 6   -16 2.5           -6.4
 7   -24 2.63          -9.11
 8    11 0.883         12.5
 9     5 2.33           2.14
10   -10 2.3           -4.35
# i 336,766 more rows
```

4. Modifier des données

`mutate()` : fonctions utiles

Toute fonction prenant un vecteur en argument et retournant un vecteur de même longueur.

- Opérateurs arithmétiques : +, −, *, /, ^
- Arithmétique modulaire : %/% et %%
- Logarithmes : `log()`, `log10()` et `log2()`
- Décalages : `lag()` et `lead()`
- Fonctions aggrégatives cumulées : `cumsum()`, `cummean()`, `cumprod()`, `cummin()`, `cummax()`
- Comparaisons logiques : <, >, <=, >=, ==, !=
- Fonctions de rang : `min_rank()`, `desc()`, `row_number()`, `dense_rank()`, `percent_rank()`, `cume_dist()`, `ntile()`, ...

4. Modifier des données

`mutate()` : exercices

1. Actuellement, `dep_time` et `sched_dep_time` sont pratiques à examiner, mais il est difficile d'effectuer des calculs avec ces variables car ce ne sont pas réellement des nombres continus. Transformez-les en nombre de minutes depuis minuit, ce qui sera plus facile à manipuler
2. Comparez `air_time` à `arr_time - dep_time`. Que devriez-vous trouver ? Qu'obtenez vous ? Que faire pour régler le problème ?
3. Comparez `dep_time`, `sched_dep_time` et `dep_delay`. Quelle relation vous attendez-vous à observer entre ces 3 variables ?
4. Trouvez les 10 vols les plus retardés en utilisant une fonction de rang. Comment souhaitez-vous traiter les égalités ? Lisez attentivement la documentation de `min_rank()`.
5. Quel est le résultat de `1:3 + 1:10` ? Pourquoi ?

Manipuler des données : 5. Résumer

5. Résumer des données

La fonction `summarise()` : principe

Le dernier verbe essentiel est `summarise()`. Il permet de réduire un jeu de données à une unique ligne :

```
summarise(flights, delay = mean(dep_delay, na.rm = TRUE))
```

```
# A tibble: 1 x 1
  delay
  <dbl>
1  12.6
```

Ici, nous apprenons que sur l'ensemble des vols de 2013, le retard moyen des vols au départ vaut 12.6 minutes.

`summarise()` n'est pas terriblement utile quand on l'utilise seule. Mais en combinaison avec `group_by()`, ça change tout...

5. Résumer des données

La fonction `summarise()` : principe

Ainsi, en appliquant la même fonction aux données groupées par mois, on obtient aisément la moyenne mensuelle des retards :

```
by_month <- group_by(flights, year, month)
summarise(by_month, delay = mean(dep_delay, na.rm = TRUE))

# A tibble: 12 x 3
# Groups:   year [1]
    year month delay
   <int> <int> <dbl>
 1  2013     1 10.0
 2  2013     2 10.8
 3  2013     3 13.2
 4  2013     4 13.9
 5  2013     5 13.0
 6  2013     6 20.8
 7  2013     7 21.7
 8  2013     8 12.6
 9  2013     9  6.72
10  2013    10  6.24
11  2013    11  5.44
12  2013    12 16.6
```

Les résumés groupés sont très utiles lors de l'exploration des données.

5. Résumer des données

summarise() : digression, le pipe

Imaginons le scénario suivant : nous souhaitons étudier la relation entre la **distance parcourue** en vol d'une part et les **retards observés à l'arrivée** pour chaque destination d'autre part.

En utilisant ce nous avons vu jusqu'ici, nous pourrions taper le code suivant [2] :

```
by_dest <- group_by(flights, dest)
delay <- summarise(by_dest,
  count = n(),
  dist = mean(distance, na.rm = TRUE),
  delay = mean(arr_delay, na.rm = TRUE)
)
delay_clean <- filter(delay, count > 20, dest != "HNL")
```

2. On commence par grouper les vols par destination. On calcule ensuite, pour chaque destination, le nombre de vols, la distance moyenne parcourue et le retard moyen à l'arrivée. Enfin, on élimine les destinations trop peu fréquentées ainsi qu'Honolulu (qui est 2 fois plus éloignée que toutes les autres destinations)

5. Résumer des données

summarise() : digression, le pipe

```
ggplot(data = delay_clean, mapping = aes(x = dist, y = delay)) +
  geom_point(aes(size = count), alpha = 1/3) +
  geom_smooth(se = FALSE)
```

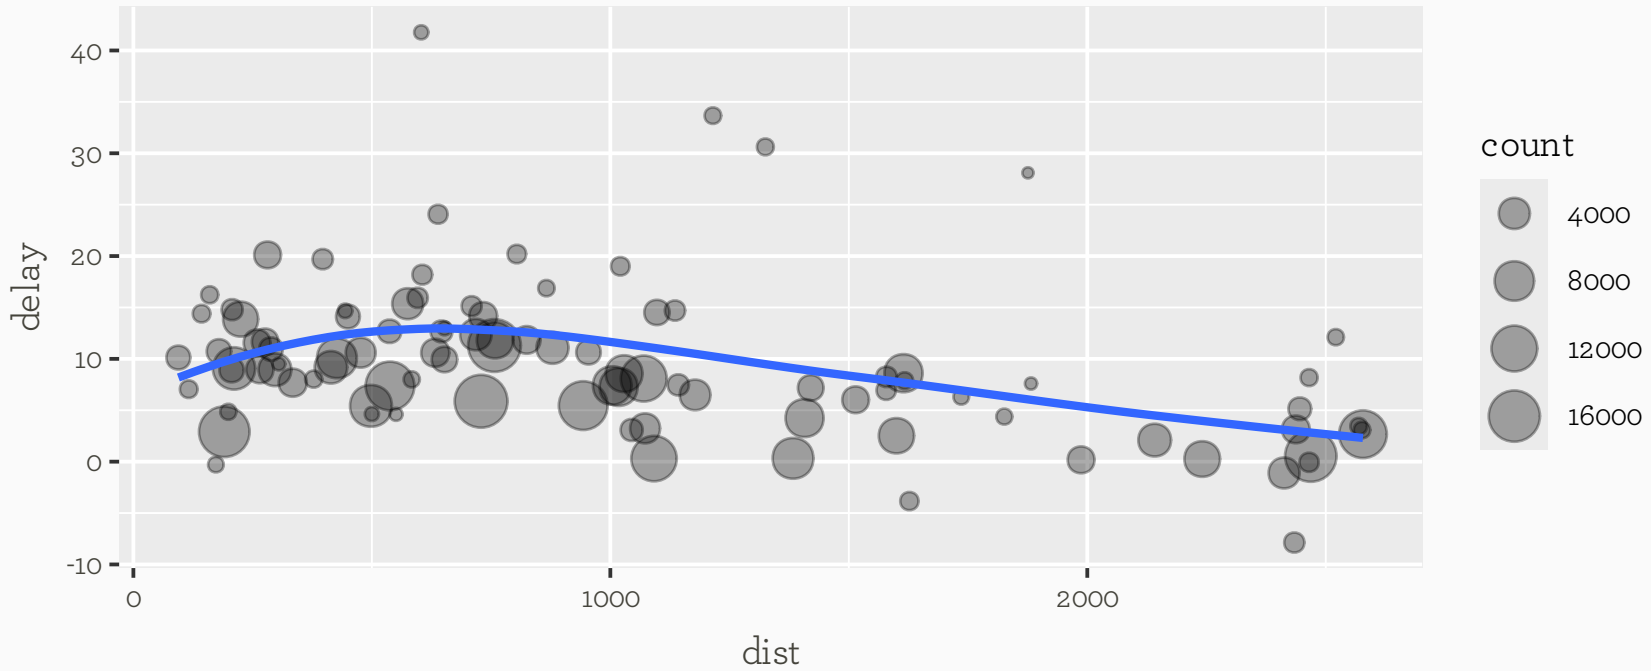

Les retards augmentent avec la distance, jusqu'à 700 km environ, puis la relation est négative. C'est comme si les vols plus longs permettaient de rattraper une partie du retard accumulé au départ.

5. Résumer des données

`summarise()` : digression, le pipe

Nous avons donc ici utilisé 4 (groupes de) fonctions :

1. `group_by()`
2. `summarise()`
3. `filter()`
4. `ggplot()` et autres fonctions associées

L'un des problèmes de cette approche est que nous avons dû créer des objets intermédiaires dont le contenu ne nous intéresse pas vraiment :

1. `by_dest`
2. `delay`
3. `delay_clean`

Nommer est difficile et cette syntaxe met l'accent sur les objets au lieu de mettre l'accent sur les actions réalisées.

5. Résumer des données

summarise() : digression, le pipe

L'alternative ? Utiliser le pipe %>% !

```
delays <- flights %>%
  group_by(dest) %>%
  summarise(
    count = n(),
    dist = mean(distance, na.rm = TRUE),
    delay = mean(arr_delay, na.rm = TRUE)
    ) %>%
  filter(count > 20, dest != "HNL")
```

Concrètement, le pipe récuppère l'objet qui est à gauche et le transmet à la fonction qui suit en tant que premier argument.

Ainsi,

- `x %>% f(y)` est équivalent à `f(x, y)`
- `x %>% f(y) %>% g(z)` est équivalent à `g(f(x, y), z)`

5. Résumer des données

summarise() : digression, les valeurs manquantes

Il est important de spécifier la façon dont les NAs doivent être traités :

```
flights %>%
  group_by(year, month, day) %>%
  summarise(mean = mean(dep_delay))

# A tibble: 365 x 4
# Groups:   year, month [12]
    year month   day  mean
   <int> <int> <int> <dbl>
 1  2013     1     1    NA
 2  2013     1     2    NA
 3  2013     1     3    NA
 4  2013     1     4    NA
 5  2013     1     5    NA
 6  2013     1     6    NA
 7  2013     1     7    NA
 8  2013     1     8    NA
 9  2013     1     9    NA
10  2013     1    10    NA
# i 355 more rows
```

5. Résumer des données

`summarise()` : digression, les valeurs manquantes

Ici, il y a 2 façons de faire :

1. On peut spécifier à la fonction `mean()` que faire des valeurs manquantes :

```
flights %>%
  group_by(year, month, day) %>%
  summarise(mean = mean(dep_delay, na.rm = TRUE))
```

2. On peut filtrer les valeurs manquantes en amont.[3] Donnons un nom à cet objet que nous ré-utiliserons plus tard.

```
not_cancelled <- flights %>%
  filter(!is.na(dep_delay), !is.na(arr_delay))

not_cancelled %>%
  group_by(year, month, day) %>%
  summarise(mean = mean(dep_delay))
```

3. Ici, les valeurs manquantes représentent des vols annulés.

5. Résumer des données

summarise() : les comptages

Quand on aggrège, il est toujours utile d'intégrer soit le nombre d'observations, soit le nombre d'observations hors valeurs manquantes.

```
delays <- not_cancelled %>%
  group_by(tailnum) %>%
  summarise(delay = mean(arr_delay))

ggplot(data = delays, aes(x = delay)) + geom_freqpoly(binwidth = 10)
```

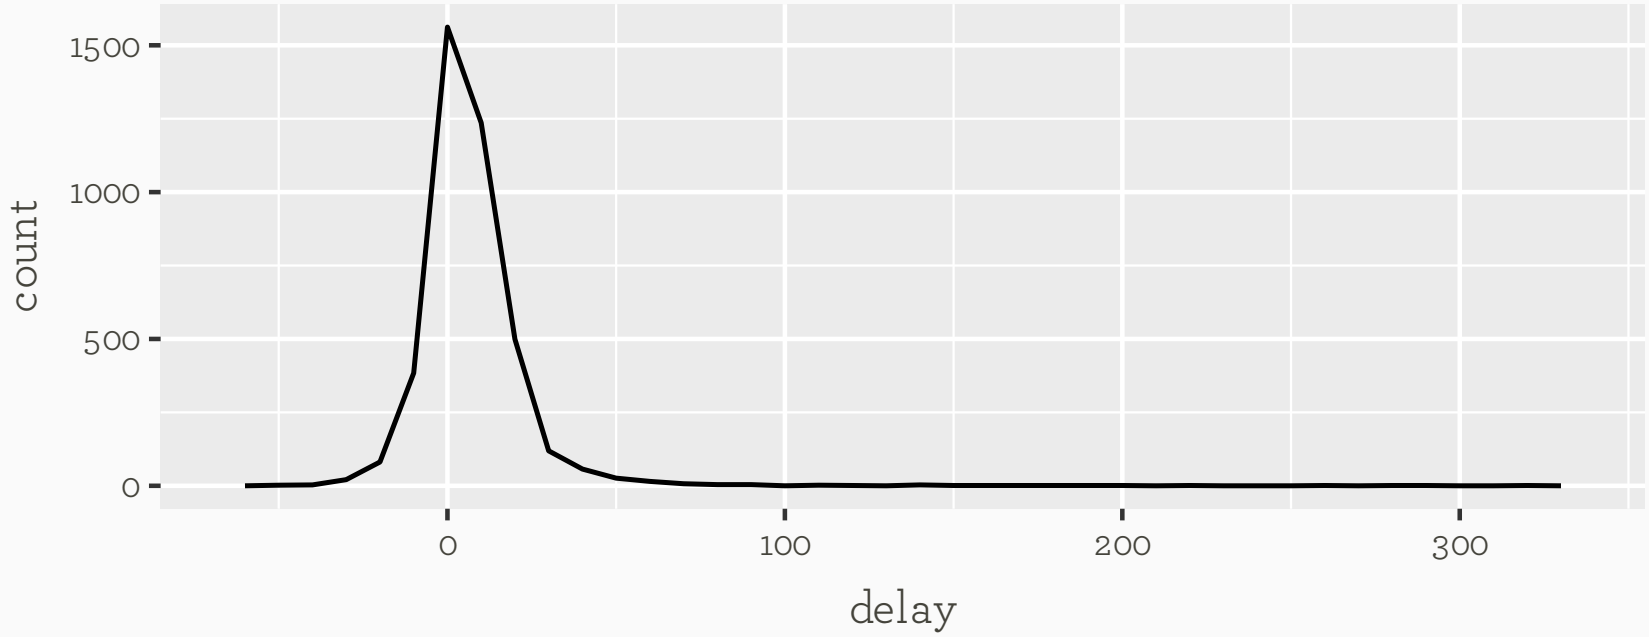

5. Résumer des données

summarise() : les comptages

```
delays <- not_cancelled %>%
  group_by(tailnum) %>%
  summarise(delay = mean(arr_delay),
            n = n())

ggplot(data = delays, aes(x = n, y = delay)) +
  geom_point(alpha = 1/10)
```

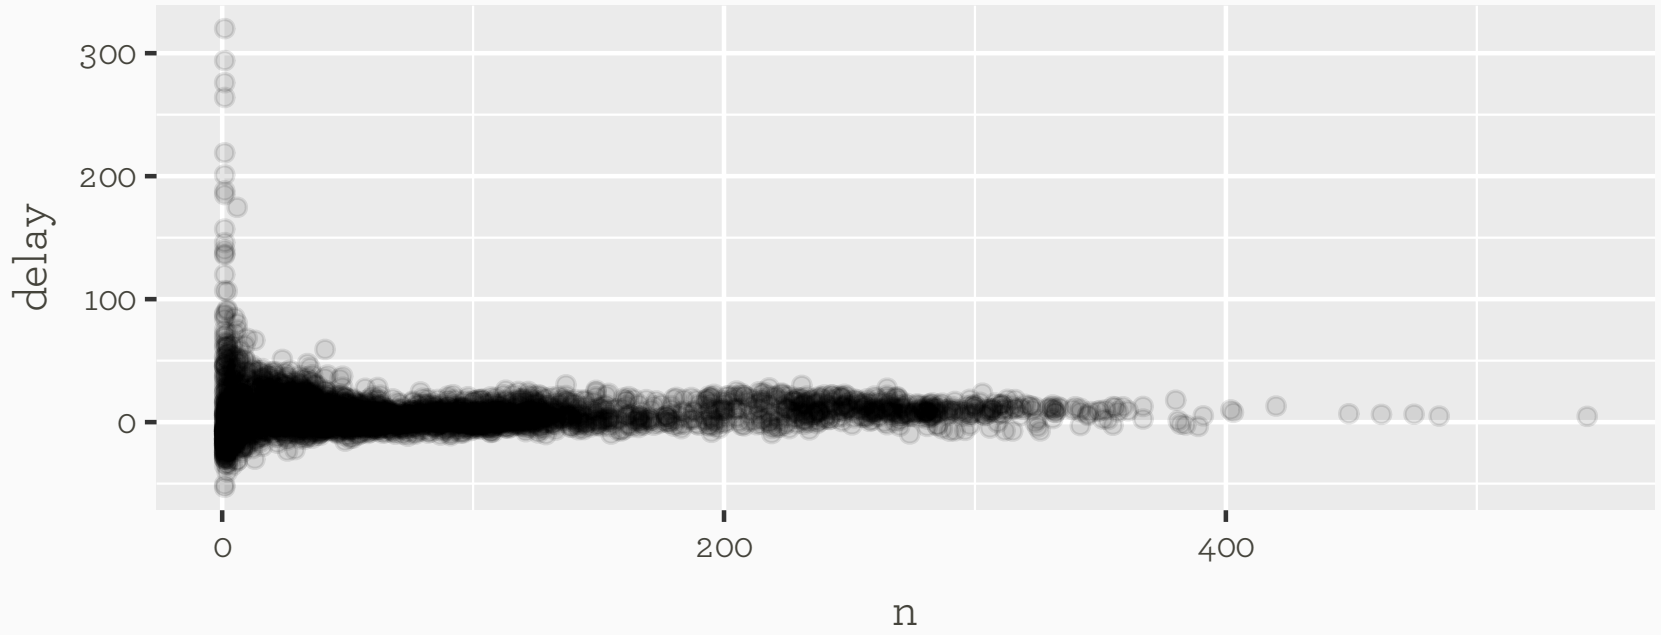

5. Résumer des données

summarise() : les comptages

```
delays %>%
  filter(n > 25) %>%
  ggplot(aes(x = n, y = delay)) +
    geom_point(alpha = 1/10)
```

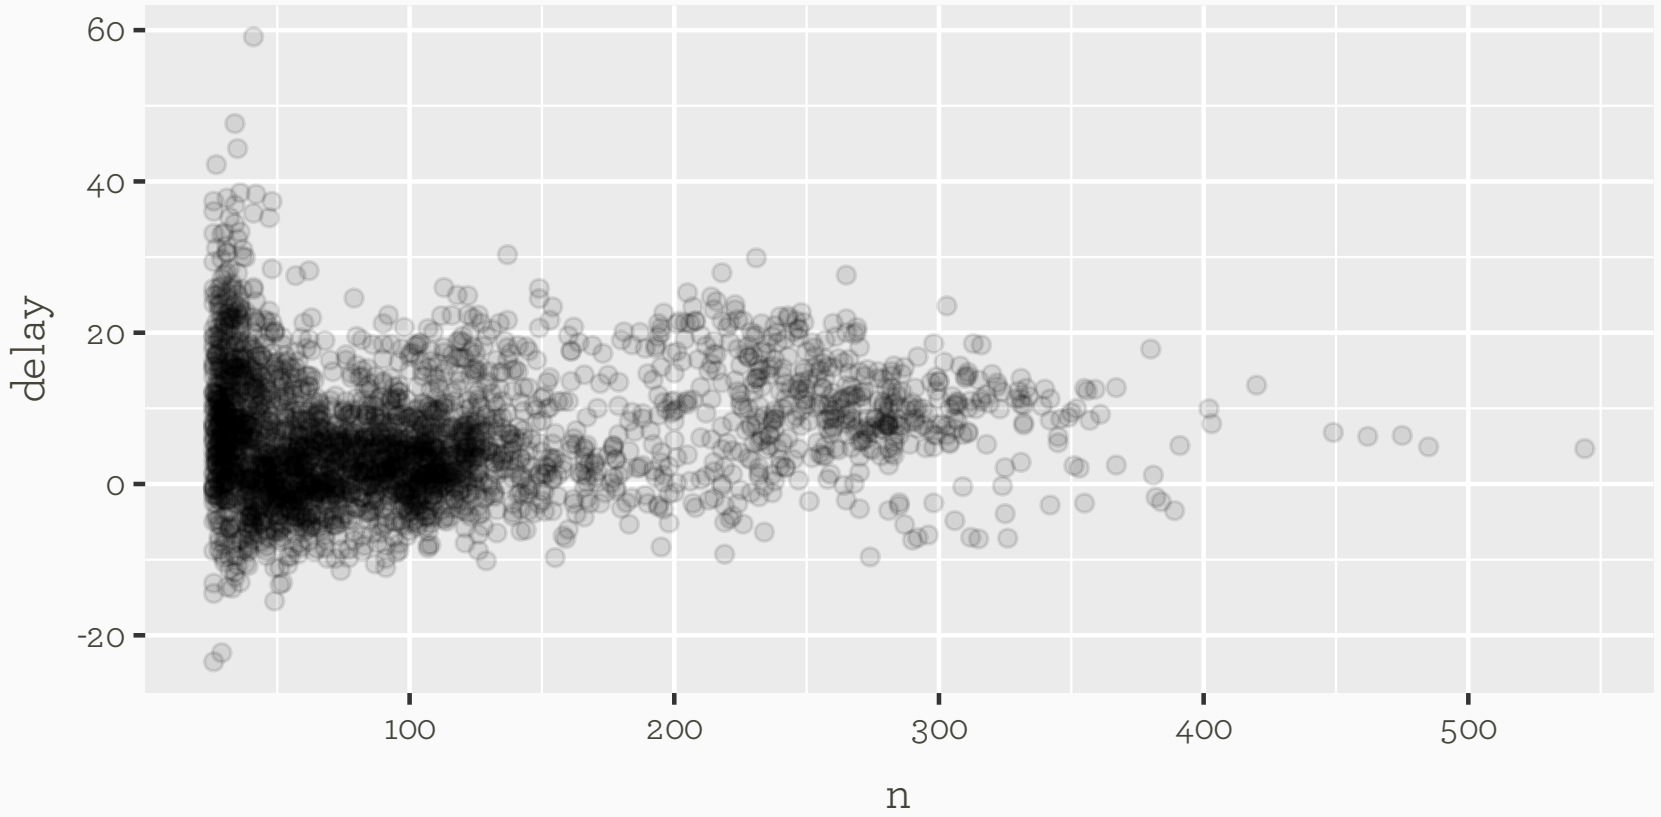

5. Résumer des données

`summarise()` : autres fonctions utiles

L'utilisation de "subsets" est souvent utile pour obtenir des résumés sur une partie seulement des données :

```
not_cancelled %>%
  group_by(year, month, day) %>%
  summarise(
    avg_delay1 = mean(arr_delay),
    avg_delay2 = mean(arr_delay[arr_delay > 0])
    )

# A tibble: 365 x 5
# Groups:   year, month [12]
   year month   day avg_delay1 avg_delay2
  <int> <int> <int>      <dbl>      <dbl>
1  2013     1     1      12.7        32.5
2  2013     1     2      12.7        32.0
3  2013     1     3       5.73       27.7
4  2013     1     4      -1.93       28.3
5  2013     1     5      -1.53       22.6
6  2013     1     6       4.24       24.4
# i 359 more rows
```

5. Résumer des données

summarise() : autres fonctions utiles

Les mesures de dispersion : var(), sd(), IQR(), mad()...

```
# Pourquoi la distance vers certaines destinations
# est-elle plus variable que d'autres ?
not_cancelled %>%
  group_by(dest) %>%
  summarise(distance_sd = sd(distance)) %>%
  arrange(desc(distance_sd))
```

```
# A tibble: 104 x 2
  dest  distance_sd
  <chr>       <dbl>
1 EGE         10.5
2 SAN         10.4
3 SFO         10.2
4 HNL         10.0
5 SEA          9.98
6 LAS          9.91
# i 98 more rows
```

5. Résumer des données

summarise() : autres fonctions utiles

Les mesures de rang : `min()`, `max()`, `quantile(x, 0.25)`…

```
# À quelle heure décollent les premiers et derniers vols chaque jour ?
not_cancelled %>%
  group_by(year, month, day) %>%
  summarise(
    first = min(dep_time),
    last = max(dep_time)
    )

# A tibble: 365 x 5
# Groups:   year, month [12]
   year month   day first  last
  <int> <int> <int> <int> <int>
1  2013     1     1   517  2356
2  2013     1     2    42  2354
3  2013     1     3    32  2349
4  2013     1     4    25  2358
5  2013     1     5    14  2357
6  2013     1     6    16  2355
# i 359 more rows
```

5. Résumer des données

summarise() : autres fonctions utiles

Les mesures de position : `first(x)`, `nth(x, 2)`, `last(x)`…

```
# À quelle heure décollent les premiers et derniers vols chaque jour ?
not_cancelled %>%
  group_by(year, month, day) %>%
  summarise(
    first = first(dep_time),
    last = last(dep_time)
    )

# A tibble: 365 x 5
# Groups:   year, month [12]
   year month   day first  last
  <int> <int> <int> <int> <int>
1  2013     1     1   517  2356
2  2013     1     2    42  2354
3  2013     1     3    32  2349
4  2013     1     4    25  2358
5  2013     1     5    14  2357
6  2013     1     6    16  2355
# i 359 more rows
```

5. Résumer des données

summarise() : autres fonctions utiles

Les fonctions de comptage : `n()`, `sum(!is.na(x))`, `n_distinct()`...

```
# Quelles sont les destinations désservies
# par le plus grand nombre de compagnies ?
not_cancelled %>%
  group_by(dest) %>%
  summarise(n_carriers = n_distinct(carrier)) %>%
  arrange(desc(n_carriers))
```

```
# A tibble: 104 x 2
  dest  n_carriers
  <chr>      <int>
1 ATL            7
2 BOS            7
3 CLT            7
4 ORD            7
5 TPA            7
6 AUS            6
# i 98 more rows
```

5. Résumer des données

`summarise()` : autres fonctions utiles

Les fonctions de comptage :

L'opération qui consiste à grouper puis à résumer par un simple comptage est tellement courante que `dplyr` fournit un raccourci : `count()`.

```
# Combien de vols ont atteint chaque destination ?
not_cancelled %>%
  count(dest)

# A tibble: 104 x 2
  dest      n
  <chr> <int>
1 ABQ     254
2 ACK     264
3 ALB     418
4 ANC       8
5 ATL   16837
6 AUS    2411
# i 98 more rows
```

5. Résumer des données

`summarise()` : autres fonctions utiles

Les fonctions de comptage :

On peut même fournir une pondération avec l'argument `wt`, qui permet ainsi de calculer des sommes.

```
# Quelle distance chaque appareil a-t'il parcourue ?
not_cancelled %>%
  count(tailnum, wt = distance)

# A tibble: 4,037 x 2
  tailnum      n
  <chr>    <dbl>
1 D942DN    3418
2 N0EGMQ  239143
3 N10156  109664
4 N102UW   25722
5 N103US   24619
6 N104UW   24616
# i 4,031 more rows
```

5. Résumer des données

summarise() : autres fonctions utiles

Les fonctions de comptage : nombres et proportions de valeurs logiques.

Utilisés avec des fonctions telles que sum() et mean(), les TRUE sont transformés en 1 et les FALSE en 0. Les sommes donnent donc le nombre de vrais et les moyennes la proportion de vrais.

```
# Combien de vols ont décollé avant 5h00 ?
# (cela indique généralement des vols en retard de la veille)

not_cancelled %>%
  group_by(year, month, day) %>%
  summarise(n_early = sum(dep_time < 500))

# A tibble: 365 x 4
# Groups:   year, month [12]
   year month   day n_early
  <int> <int> <int>   <int>
1  2013     1     1       0
2  2013     1     2       3
3  2013     1     3       4
4  2013     1     4       3
5  2013     1     5       3
6  2013     1     6       2
# i 359 more rows
```

5. Résumer des données

summarise() : autres fonctions utiles

Les fonctions de comptage : nombres et proportions de valeurs logiques.

Utilisés avec des fonctions telles que sum() et mean(), les TRUE sont transformés en 1 et les FALSE en 0. Les sommes donnent donc le nombre de vrais et les moyennes la proportion de vrais.

```
# Quelle proportion de vols est arrivée avec plus d'une heure de retard ?

not_cancelled %>%
  group_by(year, month, day) %>%
  summarise(hour_perc = mean(arr_delay > 60))

# A tibble: 365 x 4
# Groups:   year, month [12]
   year month   day hour_perc
  <int> <int> <int>     <dbl>
1  2013     1     1    0.0722
2  2013     1     2    0.0851
3  2013     1     3    0.0567
4  2013     1     4    0.0396
5  2013     1     5    0.0349
6  2013     1     6    0.0470
# i 359 more rows
```

5. Résumer des données

`summarise()` : exercices

1. Proposez une autre façon d'obtenir les mêmes résultats que ceux produits par cette commande (sans utiliser `count()`) :

```
not_cancelled %>%
  count(dest)
```

2. Examinez le nombre de vol annulés chaque jour. Y a-t'il une tendance ? Est-ce que la proportion de vols annulés est liée au retard moyen ?
3. Quelle compagnie aérienne a les retards les plus importants ? Pouvez-vous déméler la cause la plus importante de retard entre une mauvaise compagnie et une mauvaise destination (un mauvais aéroport) ? Pourquoi/comment ? Indice : essayez de partir de ceci :

```
flights %>%
  group_by(carrier, dest) %>%
  summarise(n())
```

Mise en forme : Les données rangées

Les données rangées

Le package `tidyr`

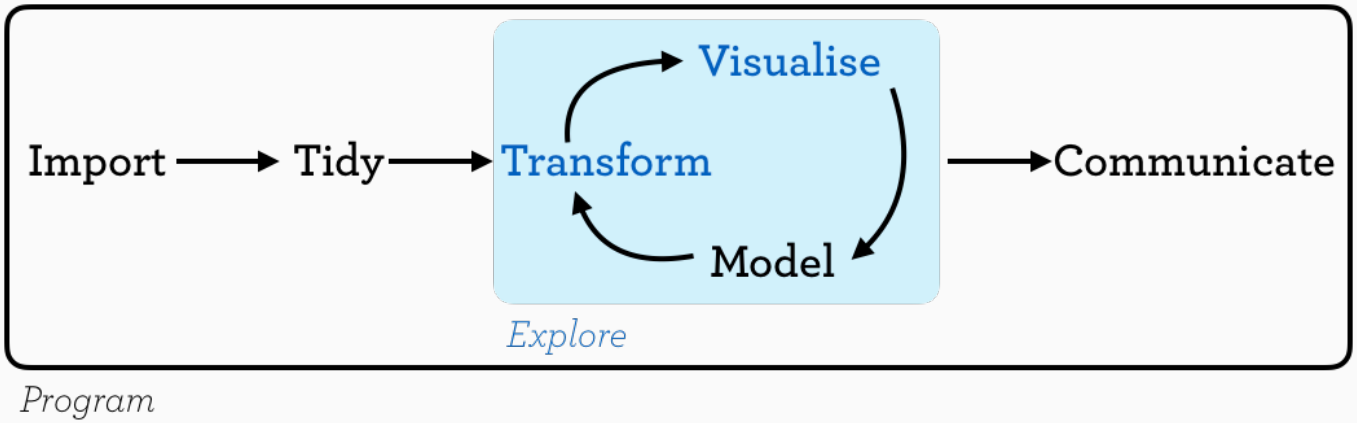

Jusqu'ici, nous avons utilisé des jeux de données dans un format idéal.

Dans la vraie vie, c'est loin d'être toujours le cas.

Bien souvent, nous aurons besoin de modifier les tableaux dont nous disposons à l'aide de 4 fonctions afin de mettre les données sous un format permettant les analyses et représentations graphiques.

Les données rangées

Le package `tidyr`

Lses 4 fonctions dont nous aurons besoin appartiennent toutes au package `tidyr`.

Il s'agit des fonctions suivantes :

- `pivot_longer()`, pour regrouper plusieurs colonnes en 2 variables pertinentes. Cette fonction permet de passer de tableaux "larges" à des tableaux "longs".
- `pivot_wider()`, pour faire l'opération inverse.
- `unite()`, pour unir 2 variables en une seule.
- `separate()`, pour séparer une variable en 2 variables ou plus.

Vous trouverez toutes les explications concernant le rôle de ces 4 fonctions dans le chapitre 5.1 du cours en ligne.